

# Lab 7: Programowanie AI z Azure

Speech, Vision, Document Intelligence

Materiały na kolokwium

7 grudnia 2025

## Spis treści

<b>1</b>	<b>Azure AI Speech</b>	<b>2</b>
1.1	Podstawy i Zasoby . . . . .	2
1.2	Speech-to-Text (STT) . . . . .	2
1.3	Text-to-Speech (TTS) . . . . .	4
1.4	Speech Translation . . . . .	5
1.5	Customizacja . . . . .	5
<b>2</b>	<b>Azure AI Document Intelligence</b>	<b>6</b>
2.1	Podstawy . . . . .	6
2.2	Prebuilt Models . . . . .	7
2.3	Custom Extraction . . . . .	9
<b>3</b>	<b>Azure AI Vision</b>	<b>10</b>
3.1	Image Analysis . . . . .	10
3.2	Integracja z .NET . . . . .	13
<b>4</b>	<b>Custom Vision</b>	<b>14</b>
4.1	Podstawy . . . . .	14
4.2	Classification . . . . .	14
4.3	Object Detection . . . . .	16
4.4	Trening . . . . .	17
4.5	Wdrożenie . . . . .	19
4.6	Operacje i Maintenance . . . . .	21
<b>5</b>	<b>Pytania kontrolne</b>	<b>21</b>

# 1 Azure AI Speech

## 1.1 Podstawy i Zasoby

### Azure AI Speech - Konfiguracja

#### Tworzenie zasobu:

- Resource Group → Azure AI Speech
- **Region** - wybór wpływa na latency i dostępne języki
- **Endpoint** - URL do API
- **Keys** - primary/secondary (authentication)
- Best practice: przechowywanie w Key Vault

#### Pricing tiers:

- **Free (F0)**: 5 audio hours/month STT, 0.5M characters/month TTS
- **Standard (S0)**: pay-as-you-go, unlimited, \$1/hour STT, \$4/1M chars TTS

## 1.2 Speech-to-Text (STT)

### STT - Transkrypcja Mowy → Tekst

#### Realtime STT:

- Live transcription (mikrofon, streaming audio)
- Low latency (milisekundy)
- Partial results (intermediate recognition podczas mówienia)
- Use case: live captions, voice commands, dyktowanie

#### Batch STT:

- Asynchroniczne przetwarzanie plików audio
- Duże pliki (do kilku godzin)
- Higher accuracy (więcej czasu na processing)
- Use case: call center analytics, meeting transcripts, podcasts

## Formaty Audio i Jakość

### Formaty wspierane:

- **WAV** - PCM 16 kHz mono (RECOMMENDED - best quality)
- MP3, OGG, FLAC, OPUS

### Sample rate:

- 8 kHz - telefonia (niższa jakość)
- 16 kHz - standard (recommended)
- 24 kHz, 48 kHz - higher quality

### Mikrofony:

- Mono preferred (stereo może być używany, ale mono lepszy)
- Odległość 15-30 cm od ust
- Redukcja szumów tła (noise cancellation)

### Modele jakości:

- **Neural** - najlepsza jakość (deep learning models)
- **Enhanced** - poprawiona akustyka dla specific scenarios
- Multilingual support - 100+ języków
- Automatic language detection

## Speech Studio - Testowanie

### Workflow:

1. Speech Studio → Transcribe
2. Nagraj z mikrofonu LUB upload WAV file (16 kHz mono)
3. Wybierz język rozpoznawania
4. Analize - otrzymasz transkrypcję + confidence scores

### SDK Integration (C#):

- NuGet: `Microsoft.CognitiveServices.Speech`
- `SpeechConfig` (endpoint, key, region)
- `SpeechRecognizer` (from mic / from file)
- `RecognizeOnceAsync()` - single utterance
- `StartContinuousRecognitionAsync()` - streaming

## 1.3 Text-to-Speech (TTS)

### TTS - Synteza Mowy

#### Neural TTS:

- Naturalne brzmienie (deep neural networks)
- Human-like prosody (intonacja, rytm, akcent)
- Wiele głosów: męskie, żeńskie, dzieci
- Multilingual - 100+ języków
- Emocje: neutral, cheerful, sad, angry, excited, friendly

#### Use case:

- Virtual assistants (Alexa-like)
- Accessibility - czytniki ekranu dla niewidomych
- IVR systems (Interactive Voice Response - call centers)
- E-learning platforms
- Audiobooks
- Navigation systems

### SSML - Speech Synthesis Markup Language

#### XML-based język do kontroli TTS

##### Kluczowe tagi:

- `< speak >` - root element
- `< voice name="en-US-JennyNeural" >` - wybór głosu
- `< prosody rate="fast" >` - prędkość (slow/medium/fast lub %)
- `< prosody pitch="high" >` - wysokość głosu
- `< break time="500ms" />` - pauza
- `< emphasis level="strong" >` - nacisk na słowo
- `< phoneme ph="..." >` - custom wymowa
- `< mstts:express-as style="cheerful" >` - emocje

##### Output formats:

- RAW PCM, WAV
- MP3 (różne bitrate: 48k, 128k, 192k)
- OGG Opus

## 1.4 Speech Translation

### Tłumaczenie Mowy Real-time

#### Funkcjonalność:

- Mowa (język A) → tekst (język B)
- Mowa (język A) → mowa (język B)
- Multi-language support (tłumaczenie na kilka języków jednocześnie)

#### Use case:

- International meetings/conferences
- Customer support (wielojęzyczny)
- Travel apps
- Real-time interpretation

#### Latency:

- Near real-time (1-2 sekundy opóźnienia)
- Partial translation results during speaking

## 1.5 Customizacja

### Custom Speech

#### Dostosowanie modelu STT do specific scenarios

##### Custom Acoustic Model:

- Adaptacja do środowiska (hałas, echo, akcent)
- Training data: audio recordings + transkrypcje
- Minimum kilka godzin nagrań
- Use case: call centers z hałasem tła, nietypowe akcenty

##### Custom Language Model:

- Specjalistyczne słownictwo (medyczne, techniczne, prawnicze)
- Training data: teksty z domenową terminologią
- Improve recognition of domain-specific terms

#### Proces:

1. Upload training data (audio + transcripts / text)
2. Train custom model (kilka godzin)
3. Evaluate accuracy
4. Deploy custom endpoint

### Custom Neural Voice

#### Własny głos syntezowany (TTS)

##### Wymagania:

- **Limited Access** - wymaga zatwierdzenia przez Microsoft
- Ethical use case approval (zapobieganie deepfake abuse)
- Training data: 300-2000 utterances ( 10-30 min nagrań)
- Professional recording environment

##### Proces aplikacji:

1. Submit use case description
2. Microsoft review (compliance, ethical use)
3. Approval (może zająć tygodnie)
4. Training z professional recordings

##### Use case:

- Brand voice (company assistant)
- Celebrity voice (za zgodą)
- Personalization (custom voice dla accessibility)

## 2 Azure AI Document Intelligence

### 2.1 Podstawy

#### Document Intelligence (Form Recognizer)

##### AI-powered extraction z dokumentów

##### Funkcje:

- **OCR** - Optical Character Recognition (tekst z obrazów)
- **Layout analysis** - struktura dokumentu (paragraphs, tables)
- **Key-value pairs** - pola formularzy
- **Table extraction** - dane tabelaryczne
- **Prebuilt models** - gotowe modele dla common documents
- **Custom models** - trenowanie własnych

##### Wspierane formaty:

- PDF, JPG, PNG, TIFF, BMP
- Handwriting i print text

## 2.2 Prebuilt Models

### Gotowe Modele w Studio

#### Invoices (Faktury):

- Vendor name, date, invoice number
- Total amount, tax, line items
- Currency detection
- Confidence scores dla każdego pola

#### Receipts (Paragony):

- Merchant name, transaction date, total
- Line items (products, prices)
- Payment method, tip amount

#### ID/Passport:

- Full name, date of birth, document number
- Expiration date, nationality, address
- Face detection (photo location)

#### Business Cards:

- Name, job title, company
- Phone, email, address, website

#### W-2 (US tax form):

- Employee/employer info
- Wages, tax withheld, social security

#### Read (OCR):

- Plain text extraction
- Line-by-line output
- Handwriting recognition
- Language detection

#### Layout:

- Document structure (headers, paragraphs, tables)
- Bounding boxes dla text regions
- Reading order detection
- Selection marks (checkboxes)

## Document Intelligence Studio

### Testowanie prebuilt models:

1. Document Intelligence Studio → Prebuilt models
2. Wybierz model (np. Invoices)
3. Upload 2-3 sample documents (PDF/JPG)
4. Analize - otrzymasz JSON output
5. Przejrzyj extracted fields:
  - Pola (vendor, date, total)
  - Tabele (line items)
  - Confidence scores (0. 0-1.0)
  - Bounding boxes (locations)

### JSON output structure:

- `analyzeResult. documents[]` - extracted data
- `fields` - key-value pairs z confidence
- `tables` - row/column structure
- `pages` - page-level info



## 2.3 Custom Extraction

### Custom Model - Trenowanie

#### Kiedy używać:

- Własny format dokumentu (nie covered by prebuilt)
- Specific fields potrzebne
- Multiple variants tego samego formularza

#### Proces:

1. **Przygotuj dane** - 5-15 dokumentów jednego typu (ideally 15-50)
2. **Upload do Blob Storage** - Store w Azure Storage
3. **Label fields w Studio:**
  - Draw bounding boxes wokół pól
  - Assign labels (np. "InvoiceDate", "Total")
  - Label tables (rows/columns)
4. **Train model** - kilka minut do godziny
5. **Evaluate metrics** - Precision, Recall, F1 score
6. **Test on new documents**
7. **Deploy** - use przez REST API / SDK

### Compose - Łączenie Modeli

**Problem:** Różne warianty tego samego typu formularza

**Rozwiązanie:** Compose

**Jak działa:**

- Trenuj osobny model dla każdego variantu
- Combine models w jeden composed model
- Single endpoint - Azure automatycznie wybiera właściwy model

**Use case:**

- Faktury od różnych vendorów (różne layouts)
- Formularze w różnych językach
- Historical vs nowe wersje formularza

**Max:** 100 models w jednym composed model

## Metryki Oceny

### Precision (Dokładność):

- % poprawnie wyekstraktowanych wartości spośród wszystkich extracted
- High precision = mało false positives

### Recall (Pokrycie):

- % znalezionych pól spośród wszystkich możliwych
- High recall = mało false negatives

### F1 Score:

- Harmonic mean Precision i Recall
- Balansuje obie metryki
- $F1 = 2 * (Precision * Recall) / (Precision + Recall)$

### Target:

- Precision > 0.90 (90%)
- Recall > 0.90
- F1 > 0.90

## 3 Azure AI Vision

### 3.1 Image Analysis

#### Computer Vision - Analiza Obrazów

##### Funkcje:

- **Tags** - słowa kluczowe opisujące obraz
- **Descriptions** - pełne zdania opisujące scenę
- **Dense Captions** - szczegółowe opisy różnych regionów obrazu
- **OCR (Read API)** - ekstrakcja tekstu z obrazów
- **Object Detection** - lokalizacja obiektów (bounding boxes)
- **Face Detection** - wykrywanie twarzy, wiek, emocje
- **Adult Content Detection** - klasyfikacja treści (adult/racy/gory)
- **Color Analysis** - dominujące kolory, accent color
- **Image Type** - clipart vs photo, line drawing

##### Wspierane formaty:

- JPG, PNG, GIF, BMP
- Max size: 4 MB (lub 50 MB dla Read API)

## Tags vs Descriptions vs Dense Captions

### Tags (pojedyncze słowa):

- Lista keywords: "dog", "outdoor", "grass", "playing"
- Confidence score dla każdego tagu
- Use case: search indexing, kategoryzacja

### Descriptions (całe zdania):

- Pełne zdanie: "A dog playing with a ball in a grassy field"
- 1-3 candidate descriptions z confidence
- Use case: alt text, accessibility

### Dense Captions (regionalne):

- Szczegółowe opisy różnych części obrazu
- Bounding box + opis dla każdego regionu
- Przykład: "a red car"(bbox: left door), "blue sky"(bbox: upper part)
- Use case: detailed image understanding, scene composition

### Multilingual support:

- English (default), Polish, Spanish, French, German, etc.
- Language parameter w API call

## OCR - Read API

### Ekstrakcja tekstu z obrazów

#### Charakterystyka:

- Printed i handwriting recognition
- Multi-language support (140+ języków)
- Orientation detection (auto-rotation)
- Bounding boxes dla words i lines
- Confidence scores

#### Use case:

- Document digitization
- Receipt/invoice scanning
- License plate recognition
- Street sign reading
- Handwritten notes extraction

#### Output structure:

- Pages → Lines → Words
- Każdy element ma: text, bbox, confidence
- Preserves layout structure

## Vision Studio - Testowanie

### Workflow:

1. Vision Studio → Image Analysis
2. Upload images (różne jakości - test robustness)
3. Przeglądaj results:
  - Tags (keywords)
  - Descriptions (sentences)
  - Dense Captions (regional descriptions)
  - OCR output (extracted text)
4. Zmień język opisu - compare quality
5. Test różne typy obrazów (outdoor, indoor, people, objects)

## 3.2 Integracja z .NET

### REST API vs SDK

#### REST API:

- HttpClient do wywołania endpoint
- POST request z obrazem (binary lub URL)
- Headers: Ocp-Apim-Subscription-Key
- JSON response z results

#### SDK (NuGet):

- `Azure.AI.Vision.ImageAnalysis`
- `ImageAnalysisClient` (endpoint, credential)
- Strongly-typed methods
- Easier error handling

#### Batch vs Single:

- Single - analyze jeden obraz na raz
- Batch - multiple images (async processing, lower cost per image)

### Minimal API Example - .NET 9

**Endpoint:** POST /analyze-image

#### Configuration:

- `IOptions<VisionSettings>` - endpoint, key z appsettings
- Key Vault integration dla production

#### Flow:

1. Client uploads image (multipart/form-data)
2. API wywołuje Vision REST endpoint
3. Przetwarza JSON response
4. Zwraca formatted result (tags, descriptions, OCR)

#### Error handling:

- Invalid image format → 400 Bad Request
- API quota exceeded → 429 Too Many Requests
- Unauthorized → 401 (check key)

## 4 Custom Vision

### 4.1 Podstawy

#### Custom Vision Service

**Trenowanie własnych modeli computer vision**

**2 typy projektów:**

- **Classification** - klasyfikacja obrazu (jedna lub wiele etykiet)
- **Object Detection** - lokalizacja i klasyfikacja obiektów

**Portal:** [customvision.ai](https://customvision.ai)

**Zasoby Azure:**

- Custom Vision Training - do trenowania modeli
- Custom Vision Prediction - do wdrożenia i inference
- Możliwe combined resource (training + prediction)

### 4.2 Classification

#### Klasyfikacja Obrazów

**Multiclass:**

- Jedna etykieta na obraz
- Przykład: "dog" LUB "cat" LUB "bird" (nie może być kilka jednocześnie)
- Model wybiera najbardziej prawdopodobną klasę

**Multilabel:**

- Wiele etykiet na obraz
- Przykład: "beach" + "sunset" + "people" (wszystkie mogą być true)
- Independent probability dla każdego tagu

**Kiedy który:**

- Multiclass - mutually exclusive categories
- Multilabel - multiple attributes możliwe jednocześnie

## Training Data - Classification

### Minimum:

- 5 obrazów na tag (absolute minimum)
- Recommended: 30-50 obrazów na tag
- Ideally: 100+ obrazów na tag dla production

### Balans klas:

- Podobna liczba obrazów dla każdego tagu
- Imbalance prowadzi do bias (model preferuje częstsze klasy)
- Jeśli imbalance nieunikniony: use class weights

### Różnorodność:

- Różne kąty (front, side, top views)
- Różne oświetlenie (day, night, indoor, outdoor)
- Różne tła (isolated vs cluttered)
- Różne odległości (close-up, far away)

### Augmentacje:

- Custom Vision automatycznie augmentuje
- Rotation, flip, color adjustments, zoom
- Zwiększa robustness bez dodatkowych obrazów

## 4.3 Object Detection

### Detekcja Obiektów

#### Lokalizacja + klasyfikacja obiektów

##### Proces tagowania:

- Rysuj bounding boxes wokół obiektów
- Assign tag do każdego boxa
- Możliwe wiele obiektów tego samego typu na jednym obrazie
- Tight bounding boxes (bez zbędnego marginesu)

##### Training data:

- Minimum: 15 obrazów na tag (z labeled objects)
- Recommended: 50+ obrazów
- Ideally: 200+ obrazów dla production

##### Różnorodność:

- Różne rozmiary obiektów (small, medium, large)
- Occlusion scenarios (częściowo zakryte)
- Overlapping objects
- Cluttered backgrounds



## 4.4 Trening

### Quick Training vs Advanced Training

#### Quick Training:

- Czas: kilka minut
- Mniejsza dokładność
- Fewer epochs
- Use case: prototyping, testing data quality, iteracja szybka

#### Advanced Training:

- Czas: do godziny (zależnie od data size)
- Wyższa dokładność
- More epochs, hyperparameter tuning
- Use case: production models, final deployment

#### Iteracje:

- Każdy trening tworzy nową iterację
- Wersjonowanie modeli (iteration 1, 2, 3...)
- Możesz compare performance między iteracjami
- Możesz revert do previous iteration
- Publish konkretną iterację do prediction endpoint

## Metryki - Classification

### Precision (Dokładność):

- % poprawnych positive predictions
- $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$
- High precision = few false positives

### Recall (Pokrycie):

- % znalezionych positive cases
- $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$
- High recall = few false negatives

### Trade-off:

- Increasing precision często decreases recall
- Adjust threshold aby balansować

### Target values:

- $\text{Precision} > 0.85$  (85%)
- $\text{Recall} > 0.85$
- Depends on use case (medical = high recall, spam = high precision)

## Metryki - Object Detection

### mAP (mean Average Precision):

- Primary metric dla object detection
- Combines precision i recall across all classes
- IoU threshold (Intersection over Union) - typically 0.5

### IoU (Intersection over Union):

- Miara overlap between predicted i ground truth bbox
- $\text{IoU} = \text{Area of Overlap} / \text{Area of Union}$
- $\text{IoU} > 0.5$  = good detection (często used threshold)
- $\text{IoU} > 0.75$  = excellent detection

### Target:

- $\text{mAP} > 0.70$  (70%) - good model
- $\text{mAP} > 0.85$  - excellent model
- Depends on complexity (simple objects easier than complex)

## 4.5 Wdrożenie

### Prediction Endpoint (SaaS)

#### Cloud-hosted inference:

- Publish iteration → creates REST endpoint
- Automatic scaling
- Pay per prediction
- Easy updates (deploy new iteration)

#### API calls:

- POST request z obrazem (binary lub URL)
- Headers: Prediction-Key
- JSON response: predictions z probabilities

#### Threshold adjustment:

- Default: 0.5 (50% confidence)
- Higher threshold → more precision, less recall
- Lower threshold → more recall, less precision
- Adjust based on use case requirements

## Export "On-Edge"

### Offline inference (bez cloud connectivity)

#### Supported formats:

- **ONNX** - Open Neural Network Exchange (universal)
- **TensorFlow** - pełny model
- **TensorFlow Lite** - mobilne (Android/iOS, optimized)
- **CoreML** - iOS/macOS native
- **NCNN** - Android optimized (bardzo szybki)

#### Use case:

- IoT devices (offline capability)
- Mobile apps (MAUI, native iOS/Android)
- Edge computing (low latency critical)
- Privacy concerns (data stays on device)
- Cost optimization (no per-prediction charge)

#### Trade-offs:

- (+) Offline, low latency, no recurring cost
- (-) Manual model updates, limited device resources

## 4.6 Operacje i Maintenance

### Zarządzanie Modelem

#### Iteracje:

- Train new iteration gdy dodasz więcej danych
- Compare metrics między iteracjami
- Unpublish old iteration, publish new
- Keep historical iterations (for rollback)

#### Threshold tuning:

- Test różne progi confidence
- Monitor false positives vs false negatives
- A/B testing w production (compare thresholds)

#### Data drift:

- Zmiana danych w czasie (nowe scenariusze, oświetlenie, obiekty)
- Performance degradation
- Rozwiązanie: regularny retraining z nowymi danymi
- Monitoring: track prediction confidence over time

#### Adding new data:

- Upload nowe obrazy (especially edge cases)
- Retrain model (Quick Training dla fast iteration)
- Evaluate improvement
- Deploy jeśli better performance

## 5 Pytania kontrolne

1. Czym różni się Realtime STT od Batch STT?
2. Jaki format audio jest recommended dla STT i dlaczego?
3. Co to jest Neural TTS i jakie ma zastosowania?
4. Wymień 3 tagi SSML i ich funkcje.
5. Co to jest Custom Speech i kiedy go używać?
6. Wymień 5 prebuilt models w Document Intelligence.
7. Co to jest Compose w Document Intelligence?
8. Czym różnią się Tags, Descriptions i Dense Captions?
9. Co to jest Read API i do czego służy?
10. Czym różni się Classification Multiclass od Multilabel?

11. Ile minimum obrazów potrzeba do treningu Classification?
12. Co to jest mAP w Object Detection?
13. Czym różni się Quick Training od Advanced Training?
14. Jakie formaty eksportu są dostępne w Custom Vision?
15. Co to jest data drift i jak sobie z nim radzić?